



Akademia Górniczo-Hutnicza
im. Stanisława Staszica
w Krakowie

Praca magisterska

**Uczenie funkcji
wysoko-wymiarowych o niewielkiej
liczbie parametrów liniowych –
analiza teoretyczna i numeryczna**

Maksymilian Dębowski

Kierunek: Matematyka
Specjalność: Matematyka Obliczeniowa i Komputerowa

Nr albumu: 413676

Promotor
dr Paweł Morkisz



Wydział Matematyki Stosowanej

Kraków 2026

Wstęp

Współczesna analiza numeryczna oraz uczenie maszynowe coraz częściej mierzą się z problemem aproksymacji funkcji wielu zmiennych $f : \mathbb{R}^d \rightarrow \mathbb{R}$ dla bardzo dużych wymiarów d . Klasyczne podejście do tego zagadnienia napotyka jednak fundamentalną barierę. Jak wykazali Novak i Woźniakowski [11], bez przyjęcia dodatkowych założeń o strukturze funkcji liczba próbek wymagana do osiągnięcia zadanego błędu aproksymacji rośnie wykładniczo wraz z wymiarem d . Zjawisko to, znane jako klątwa wymiarowości (ang. *curse of dimensionality*), sprawia, że znaczna część standardowych algorytmów staje się w praktyce nieefektywna obliczeniowo (ang. *intractable*).

Konstrukcja efektywnych algorytmów wymaga zatem przyjęcia modelu, w którym funkcja istotnie zależy jedynie od niewielkiej liczby parametrów. Przykładem takiego podejścia jest klasa tzw. funkcji grzbietowych (ang. *ridge functions*), wprowadzona pierwotnie w kontekście tomografii komputerowej przez Logana i Sheppa [10].

Niniejsza praca magisterska jest poświęcona analizie uogólnionego modelu funkcji postaci

$$f(x) = g(Ax),$$

gdzie $x \in \mathbb{R}^d$, macierz A ma wymiar $k \times d$ (przy założeniu, że $k \ll d$), a g jest pewną funkcją nieliniową. Model ten stanowi uogólnienie podejścia badanego m.in. przez Cohena i in. [4] w kontekście pojedynczych wektorów stochastycznych.

Głównym celem pracy jest analiza teoretyczna i numeryczna algorytmów uczenia wyżej wymienionych funkcji na podstawie niewielkiej liczby losowych próbek. Podstawę merytoryczną rozważań stanowi artykuł Fornasiera, Schnassa i Wybirała pt. *Learning Functions of Few Arbitrary Linear Parameters in High Dimensions* [7]. Została w nim zaproponowana metoda pozwalająca na odtworzenie macierzy parametrów A z prawdopodobieństwem bliskim jedności, przy użyciu liczby próbek zależnej wielomianowo od wymiaru d .

Analiza mechanizmu działania tych algorytmów wymaga zastosowania zaawansowanego aparatu matematycznego. Kluczową rolę odgrywa tu teoria próbkowania skompresowanego (ang. *compressed sensing*), a w szczególności metody stabilnej rekonstrukcji sygnałów rzadkich opracowane przez Candès, Romberga i Tao [3]. W cytowanej pracy wykazano, że gradienty badanej funkcji wykazują strukturę rzadką. Pozwala to na ich odzyskanie przy użyciu macierzy losowych spełniających własność ograniczonej izometrii (ang. *Restricted Isometry Property*, RIP). Dowód tej własności dla macierzy Bernoulliego podali Baraniuk i in. [1]. Istotnym elementem analizy jest również zjawisko koncentracji miary na sferze wysokowymiarowej, szeroko opisane przez Ledoux [9]. Gwarantuje ono, że losowo wybrane punkty z bardzo dużym prawdopodobieństwem dostarczają użytecznych informacji o funkcji.

Praca została podzielona na trzy rozdziały:

W rozdziale pierwszym wprowadzono niezbędne definicje i twierdzenia. Omówiono w nim geometrię wysokich wymiarów oraz podstawy teorii próbkowania skompresowanego. Przedstawiono również kluczowe nierówności probabilistyczne, w tym macierzowe nierówności Chernoffa w ujęciu Troppa [13], które są niezbędne do szacowania wartości osobliwych sum macierzy losowych w przypadku wielowymiarowym (dla $k > 1$).

Rozdział drugi zawiera szczegółowe omówienie analizy teoretycznej zaprezentowanej w artykule [7]. Opisano w nim algorytmy dla przypadku $k = 1$ oraz ich uogólnienie dla $k > 1$ oparte na rozkładzie SVD. Do analizy stabilności podprzestrzeni wykorzystano klasyczne twierdzenie Wedina [14], pozwalające oszacować błąd rekonstrukcji podprzestrzeni rozpiętej przez wiersze macierzy A .

Rozdział trzeci koncentruje się na aspektach praktycznych i implementacyjnych. Przedstawiono w nim wyniki eksperymentów numerycznych badających skuteczność algorytmów w obecności szumu oraz ich stabilność numeryczną. Implementację operacji macierzowych, takich jak rozkład SVD, oparto na standardowych metodach numerycznych opisanych w [8]. Rozdział ten stanowi weryfikację teoretycznych oszacowań złożoności i zbieżności w rzeczywistych warunkach obliczeniowych.

1 Podstawy teoretyczne i aparat matematyczny

Rozdział ten ma na celu zapoznanie czytelnika z aparatem matematycznym niezbędnym do konstrukcji i analizy algorytmów uczenia funkcji o niewielkiej liczbie parametrów liniowych. Zamiast jedynie wymieniać odizolowane definicje, prześledzimy, w jaki sposób poszczególne działy matematyki łączą się ze sobą, tworząc spójne fundamenty dla naszych algorytmów.

1.1 Geometria problemu i analiza macierzowa

Naszym głównym zadaniem jest skuteczna aproksymacja funkcji wielowymiarowej zdefiniowanej jako

$$f(x) = g(Ax).$$

Aby w ogóle móc mierzyć błędy tej aproksymacji oraz precyzyjnie operować na wektorach i macierzach, musimy oprzeć się na odpowiednich normach. Dla wektora $x \in \mathbb{R}^n$, jego normę l_p dla $0 < p < \infty$ definiujemy klasycznie jako

$$\|x\|_{l_p^n} := \left(\sum_{i=1}^n |x_i|^p \right)^{1/p}.$$

Z kolei do szacowania odległości pomiędzy macierzami posłużymy się normą Frobeniusa, która dla macierzy $X \in M_{n \times m}$ przyjmuje postać

$$\|X\|_F := \left(\sum_{ij} |x_{ij}|^2 \right)^{1/2}.$$

Skoro funkcja f jest w rzeczywistości kontrolowana przez macierz A , zbadanie właściwości takich macierzy staje się priorytetem. Gwarantuje nam to zredukowany rozkład według wartości osobliwych (SVD). Każdą macierz $X \in M_{n \times m}$ możemy zapisać w postaci $X = U\Sigma V^T$. Macierze $U \in M_{n \times p}$ oraz $V \in M_{m \times p}$ (gdzie $p \leq \min(n, m)$) posiadają ortonormalne kolumny, natomiast $\Sigma = \text{diag}(\sigma_1, \dots, \sigma_p)$ jest macierzą diagonalną przechowującą uporządkowane rosnąco wartości osobliwe $\sigma_1 \geq \sigma_2 \geq \dots \geq \sigma_p \geq 0$. Rozkład SVD posłuży nam w algorytmach do izolowania kluczowych parametrów kierunkowych.

1.2 Próbkowanie skompresowane (Compressed Sensing)

Zasadniczym wyzwaniem aproksymacji takich funkcji jest odtworzenie A na podstawie niewielkiej liczby zapytań i próbek. Ponieważ gradienty funkcji w tym modelu wykazują naturalną rzadkość (leżą w niskowymiarowej podprzestrzeni), wykorzystamy teorię próbkowania skompresowanego, która umożliwia stabilne odzyskiwanie tego typu sygnałów z niekompletnych danych.

Aby ta optymalizacja zadziałała, wykorzystywane przez nas macierze pomiarowe (oznaczymy je jako Φ) muszą spełniać Własność Ograniczonej Izometrii (RIP). Oznacza to, że dla pewnej stałej $0 < \delta < 1$ oraz dla wszystkich wektorów $x \in \mathbb{R}^d$ o zadanej rzadkości zachodzi relacja $(1 - \delta)\|x\|_{l_2^d}^2 \leq \|\Phi x\|_{l_2^m}^2 \leq (1 + \delta)\|x\|_{l_2^d}^2$. Gwarantuje to, że błąd odzyskiwania wektora poprzez minimalizację normy l_1 zostanie ograniczony przez błąd jego najlepszej K -członowej aproksymacji. Błąd ten definiujemy jako $\sigma_K(x)_{l_1^d} := \inf\{\|x - z\|_{l_1^d} : \#\text{supp}(z) \leq K\}$.

1.3 Koncentracja miary w wysokich wymiarach

Ponieważ pracujemy w warunkach kłótny wymiarowości, nasze metody będą opierać się na losowym próbkowaniu punktów testowych z powierzchni sfery. Matematyczny opis tego procesu wymaga zdefiniowania rotacyjnie niezmienniczej, jednostajnej miary powierzchniowej na sferze $\mathbb{S}^{d-1}$, którą oznaczamy jako $\mu_{\mathbb{S}^{d-1}}$.

W wysokich wymiarach miara ta wykazuje niezwykle silną (często wykładniczą) koncentrację, co oznacza, że losowe rzuty układają się w bardzo regularny, dający się opisać sposób. Wynikiem rzutu miary $\mu_{\mathbb{S}^{d-1}}$ na jednostkową kulę $B_{\mathbb{R}^k}$ w podprzestrzeni k -wymiarowej jest miara μ_k , wyrażona wzorem $d\mu_k(y) = \frac{\Gamma(d/2)}{\pi^{k/2}\Gamma((d-k)/2)}(1 - \|y\|_{l_2^k}^2)^{\frac{d-2-k}{2}}dy$. Charakterystyka tego rozkładu udowadnia, dlaczego tak "ślepe" losowanie punktów ostatecznie owocuje trafną reprezentacją naszej funkcji.

1.4 Gwarancje probabilistyczne i stabilność podprzestrzeni

Ze względu na stochastyczną naturę naszych algorytmów, dowody ich poprawności oprzemy o twierdzenia pozwalające szacować prawdopodobieństwo dużych odchyień od wartości oczekiwanej. Podstawowym narzędziem dla przypadku jednowymiarowego będzie Nierówność Hoeffdinga, zapewniająca nas, że suma niezależnych, ograniczonych zmiennych losowych $X_j \in [a_j, b_j]$ rzadko odbiega od swojej średniej:

$$\mathbb{P}\left\{\left|\sum_{j=1}^m X_j - \mathbb{E}\left(\sum_{j=1}^m X_j\right)\right| \geq t\right\} \leq 2e^{-\sum_{j=1}^m \frac{2t^2}{(b_j - a_j)^2}}.$$

Gdy przejdziemy do uogólnionego modelu dla $k > 1$, analizie będą podlegać sumy losowych macierzy próbkowania. Posłużymy się w tym celu Macierzową Nierównością Chernoffa, która dla sumy dodatnio półokreślonych macierzy X_j (przy ograniczeniu $\sigma_1(X_j) \leq C$) określa prawdopodobieństwo odchylenia największej wartości osobliwej od średniej $\mu_{\max}$:

$$\mathbb{P}\left\{\sigma_1\left(\sum_{j=1}^m X_j\right) - \mu_{\max} \geq s\mu_{\max}\right\} \leq k \frac{(1+s)^{\frac{1+s}{C}}}{e}.$$

Wreszcie, ponieważ nasz algorytm będzie w stanie wygenerować jedynie szacunkową macierz (różniącą się minimalnie od "prawdziwej"), konieczne będzie udowodnienie, że błąd w wartościach macierzy nie popsuje drastycznie obliczonych kierunków głównych. Zapewnia to Twierdzenie Wedina o ograniczeniu perturbacji. Gwarantuje ono stabilność podprzestrzeni niezmienniczych — pod warunkiem, że istotne wartości osobliwe są od siebie odseparowane o minimum $\bar{\alpha} > 0$, błąd podprzestrzeni można bezpiecznie ograniczyć błędem Frobeniusa między macierzami: $\|V_1 V_1^T - \hat{V}_1 \hat{V}_1^T\|_F \leq \frac{2}{\bar{\alpha}} \|B - \hat{B}\|_F$.

2 Algorytmy aproksymacji funkcji o niewielkiej liczbie parametrów liniowych

Rozdział drugi poświęcony jest szczegółowej analizie algorytmów zaproponowanych w pracy Fornasiera, Schnassa i Wybórala [7]. Głównym problemem rozważanym przez autorów jest efektywne uczenie (aproksymacja) funkcji wielowymiarowej zdefiniowanej na jednostkowej kuli w przestrzeni $\mathbb{R}^d$, przyjmującej postać $f(x) = g(Ax)$. W modelu tym A jest macierzą o wymiarach $k \times d$, a g jest funkcją k zmiennych. Kluczowym założeniem jest to, że wymiar k jest znacznie mniejszy od d ($k \ll d$). Klasyczne metody numeryczne w obliczu tak postawionego zadania natrafiają na problem praktycznej nierozwiązywalności (tzw. kłótny wymiarowości), ponieważ liczba próbek wymagana do aproksymacji rośnie wykładniczo wraz z wymiarem d . Zamiarem autorów było stworzenie algorytmów, których złożoność rośnie co najwyżej wielomianowo względem wymiaru d oraz liczby punktów pomiarowych m . Osiągnięto to dzięki umiejętnemu wykorzystaniu faktu, że jeśli funkcja zależy jedynie od kilku kombinacji liniowych zmiennych wejściowych, to jej gradienty leżą w niskowymiarowej podprzestrzeni i wykazują właściwości wektorów rzadkich lub ściśliwych. Umożliwia to zastosowanie aparatu teorii próbkowania skompresowanego (ang. compressed sensing) do stabilnego odzyskania macierzy parametrów z relatywnie niewielkiej liczby losowych zapytań o wartości funkcji. Wyprowadzenie algorytmów zaproponowanych przez Wybórala i współautorów opiera się na przybliżeniu pochodnych kierunkowych za pomocą rozwinięcia Taylora. Dla punktu próbkowania $\xi \in B_{\mathbb{R}^d}$ oraz kierunku $\varphi \in B_{\mathbb{R}^d}(r)$, i dla odpowiednio małego parametru $\epsilon \in \mathbb{R}_+$, zachodzi następująca tożsamość:

$$[\nabla g(A\xi)^T A] \varphi = \frac{f(\xi + \epsilon \varphi) - f(\xi)}{\epsilon} - \frac{\epsilon}{2} [\varphi^T \nabla^2 f(\zeta) \varphi],$$

gdzie ζ jest odpowiednio dobranym punktem pośrednim z otoczenia. Powtarzając takie przybliżenie dla m_Φ losowych kierunków (tworzących macierz Φ) oraz $m_{\mathcal{X}}$ punktów próbkowania (tworzących zbiór $\mathcal{X}$), algorytmy sprowadzają problem identyfikacji parametrów do układu równań:

$$\Phi X = Y - \mathcal{E}$$

gdzie Y to macierz różnic skończonych (estymat pochodnych), $\mathcal{E}$ to błąd przybliżenia wzoru Taylora, a nieznana macierz X ma specyficzną strukturę $X = A^T \mathcal{G}^T$ (dla macierzy gradientów $\mathcal{G}$). Kolumny macierzy X stanowią kombinacje liniowe wierszy macierzy A , przez co są ściśliwe. Z uwagi na to, że układ ten reprezentuje problem z dziedziny compressed sensing, w pierwszym kroku obu algorytmów kolumny macierzy

X są estymowane niezależnie za pomocą minimalizacji normy l_1 , dając przybliżenie $\hat{X}$.

Dalsze procedury zależą od wymiaru parametru:

1. W przypadku jednowymiarowym ($k = 1$, Algorytm 1): Macierz A redukuje się do pojedynczego wektora a . Wektory odzyskane za pomocą minimalizacji l_1 są przeskalowanymi kopiami wektora a^T . Algorytm wyznacza ostateczne przybliżenie $\hat{a}$ po prostu jako znormalizowany wektor $\hat{x}_j$ posiadający największą normę l_2 (co odpowiada punktowi o największym gradiencie).
2. W przypadku wielowymiarowym ($k \geq 1$, Algorytm 2): Struktura jest bardziej złożona. Aby wyekstrahować poprawną bazę z macierzy przybliżeń $\hat{X}$, algorytm stosuje rozkład według wartości osobliwych (SVD) dla macierzy $\hat{X}^T$. Ponieważ prawdziwa macierz X ma rząd nie większy niż k , przybliżenie macierzy $\hat{A}$ jest konstruowana z k prawych wektorów osobliwych odpowiadających największym wartościom osobliwym macierzy $\hat{X}^T$.

2.1 Formalna definicja modelu i założenia gładkości

Aby precyzyjnie analizować problem uczenia wysokowymiarowych funkcji, musimy w pierwszej kolejności zdefiniować klasę obiektów, którymi będziemy się zajmować. Rozważamy funkcje f zdefiniowane na rozszerzonej jednostkowej kuli euklidesowej $B_{\mathbb{R}^d}(1 + \bar{\epsilon})$ (gdzie $\bar{\epsilon} > 0$ pozwala na analizę gradientów również na brzegu kuli $B_{\mathbb{R}^d}$). Zakładamy, że nasza funkcja celowa przyjmuje postać uogólnionego modelu:

$$f(x) = g(Ax)$$

Podajcie to uogólnia prostsze modele badane wcześniej w literaturze (takie jak model jednego wektora stochastycznego czy funkcje zależne tylko od kilku aktywnych współrzędnych) poprzez wprowadzenie dowolnej macierzy parametrów liniowych.

W modelu tym parametry i funkcje muszą spełniać następujące warunki, które warunkują sukces algorytmów uczenia:

2.1.1 Założenia dotyczące macierzy A (parametry liniowe)

Macierz A ma wymiary $k \times d$, gdzie wymiar ukryty k jest zazwyczaj dużo mniejszy od wymiaru przestrzeni d ($k \ll d$). Zakładamy, że wiersze tej macierzy należą do przestrzeni l_q^d dla pewnego parametru $0 < q \leq 1$, co gwarantuje ich „ściśliwość” (ang. *compressibility*). Oznacza to spełnienie nierówności:

$$\left(\sum_{j=1}^d |a_{ij}|^q \right)^{1/q} \leq C_1$$

dla pewnej dodatniej stałej C_1 . Co ciekawe, początkowa ogólność macierzy A może zostać zredukowana. Wykorzystując zredukowany rozkład według wartości osobliwych (SVD), mianowicie $A = U\Sigma V^T$, możemy zdefiniować nową funkcję nieliniową $\tilde{g}(y) = g(U\Sigma y)$ oraz nową macierz parametrów $\tilde{A} = V^T$. Pozwala to – przy odpowiedniej modyfikacji stałych modelu – bez straty ogólności założyć, że macierz A posiada ortonormalne wiersze, co zapisujemy jako $AA^T = I_k$.

2.1.2 Założenia dotyczące funkcji nieliniowej g

Funkcja g musi być dobrze określona na obrazie dziedziny przekształconej przez macierz A , to znaczy na zbiorze $B_{\mathbb{R}^k}(1+\bar{\epsilon})$. Aby nasze algorytmy mogły opierać się na rozwinięciu Taylora, wymagamy odpowiedniej gładkości. Oczekujemy, że $g \in C^2(B_{\mathbb{R}^k}(1+\bar{\epsilon}))$. Co więcej, wartości funkcji oraz jej pochodne do drugiego rzędu włącznie muszą być jednostajnie ograniczone przez stałą C_2 :

$$\max_{|\alpha| \leq 2} \|D^\alpha g\|_\infty \leq C_2.$$

2.1.3 Warunek dobrego uwarunkowania (macierz H^f)

Same założenia o gładkości i ściśliwości nie są wystarczające do uniknięcia klątwy wymiarowości. Jeżeli funkcja byłaby "zbyt płaska" w kierunkach zdefiniowanych przez macierz A , zlokalizowanie tych kierunków na podstawie losowych próbek wymagałoby wykładniczej liczby zapytań. Aby zapobiec takiej sytuacji, wprowadzamy macierz kowariancji gradientów H^f , zdefiniowaną jako całka na sferze $\mathbb{S}^{d-1}$ względem rotacyjnie niezmienniczej miary jednostajnej $\mu_{\mathbb{S}^{d-1}}$:

$$H^f := \int_{\mathbb{S}^{d-1}} \nabla f(x) \nabla f(x)^T d\mu_{\mathbb{S}^{d-1}}(x).$$

Wykorzystując regułę łańcuchową, możemy zauważyć, że $\nabla f(x) = A^T \nabla g(Ax)$, przez co otrzymujemy zależność:

$$H^f = A^T \cdot \int_{\mathbb{S}^{d-1}} \nabla g(Ax) \nabla g(Ax)^T d\mu_{\mathbb{S}^{d-1}}(x) \cdot A.$$

Z tożsamości tej wprost wynika, że rząd macierzy H^f wynosi co najwyżej k . Dla naszego problemu kluczowe jest założenie o silnym uwarunkowaniu tej macierzy. Żądamy, aby jej wartości osobliwe były istotnie oddzielone od zera:

$$\sigma_1(H^f) \geq \dots \geq \sigma_k(H^f) \geq \alpha > 0$$

dla ustalonej stałej $\alpha > 0$. Warunek ten, stanowiący rdzeń całej analizy, gwarantuje nam, że sygnał pochodzący z aktywnych parametrów liniowych nie zniknie w zgiełku wysokich wymiarów.

2.2 Aproksymacja funkcji jednowymiarowej (Algorytm 1) – Szczegółowe omówienie przypadku $k = 1$ dla funkcji grzbietowych (ang. ridge functions), w tym zapis algorytmu oraz metody wyboru optymalnego wektora kierunkowego $\hat{a}$.

W celu łagodnego wprowadzenia do metodyki odzyskiwania parametrów liniowych, analizę rozpoczynamy od najprostszego przypadku, w którym wymiar $k = 1$. W tej sytuacji macierz parametrów A redukuje się do pojedynczego wektora wierszowego

$a = (a_1, \dots, a_d) \in \mathbb{R}^d$, o jednostkowej normie $\|a\|_{l_2^d} = 1$. Rozważana przez nas funkcja przyjmuje postać klasycznej funkcji grzbietowej (ang. ridge function):

$$f(x) = g(a \cdot x),$$

gdzie $g : B_{\mathbb{R}}(1 + \bar{\epsilon}) \rightarrow \mathbb{R}$ jest nieznaną funkcją nieliniową. Podstawowym narzędziem wykorzystywanym do ekstrakcji informacji o wektorze a z wartości funkcji f jest rozwinięcie w szereg Taylora. Wybierając punkt próbkowania $\xi \in B_{\mathbb{R}^d}$ oraz wektor kierunkowy $\varphi \in B_{\mathbb{R}^d}(r)$ (przy czym długość kroku ϵ oraz promień r spełniają warunek $r\epsilon \leq \bar{\epsilon}$), pochodną kierunkową możemy przybliżyć za pomocą ilorazu różnicowego:

$$[g'(a \cdot \xi)a] \cdot \varphi = \frac{f(\xi + \epsilon\varphi) - f(\xi)}{\epsilon} - \frac{\epsilon}{2}[\varphi^T \nabla^2 f(\zeta)\varphi]$$

gdzie ζ jest odpowiednim punktem pośrednim z kuli $B_{\mathbb{R}^d}(1 + \bar{\epsilon})$. Dzięki założeniom gładkościowym modelu, człon błędu zawierający hesjan $\nabla^2 f(\zeta)$ jest jednostajnie ograniczony. Aby przekształcić to pojedyncze równanie w układ pozwalający na zastosowanie metod próbkowania skompresowanego, algorytm generuje dwa losowe zbiory punktów: Zbiór $m_{\mathcal{X}}$ punktów próbkowania $\mathcal{X} = \{\xi_j \in \mathbb{S}^{d-1} : j = 1, \dots, m_{\mathcal{X}}\}$, wylosowanych zgodnie z jednostajną miarą powierzchniową $\mu_{\mathbb{S}^{d-1}}$ na sferze. Zbiór m_{Φ} kierunków Φ , zdefiniowanych jako wektory losowe o składowych przyjmujących wartości z rozkładu Bernoulliego. Elementy te tworzą jednocześnie macierz pomiarową Φ o wymiarach $m_{\Phi} \times d$. Dla każdego punktu ξ_j i kierunku φ_i , powyższe przybliżenie Taylora można zapisać w postaci zwartej równania macierzowego:

$$Y = \Phi X + \mathcal{E}$$

gdzie poszczególne macierze mają następujące znaczenie: Y to macierz pomiarów o wymiarach $m_{\Phi} \times m_{\mathcal{X}}$, której elementy to ilorazy różnicowe

$$y_{ij} = \frac{f(\xi_j + \epsilon\varphi_i) - f(\xi_j)}{\epsilon}.$$

$\mathcal{E}$ to macierz błędów aproksymacji Taylora o elementach

$$\epsilon_{ij} = \frac{\epsilon}{2}[\varphi_i^T \nabla^2 f(\zeta_{ij})\varphi_i].$$

X to poszukiwana macierz o wymiarach $d \times m_{\mathcal{X}}$, której kolumny stanowią przeskalowane kopie poszukiwanego wektora a^T , to znaczy $x_j = g'(a \cdot \xi_j)a^T$. Ponieważ zakłada się, że wektor a jest ściśliwy (może być dobrze aproksymowany przez wektor rzadki w normie l_1), każda kolumna macierzy X dziedziczy tę własność. Pozwala to na niezależne odzyskanie kolumn macierzy X na drodze klasycznej optymalizacji l_1 , co stanowi fundament Algorytmu 1.

Algorithm 1 Algorytm aproksymacji dla $k = 1$

Inicjalizacja i pomiary: Dla zadanych parametrów m_Φ oraz $m_\mathcal{X}$, wygeneruj losowe zbiory Φ i $\mathcal{X}$, a następnie skonstruuj macierz różnic skończonych Y opierając się na ewaluacjach czarnej skrzynki dla funkcji f .

Minimalizacja l_1 : Dla każdej kolumny y_j macierzy Y (gdzie $j = 1, \dots, m_\mathcal{X}$), znajdź estymatę kierunku $\hat{x}_j = \Delta(y_j) := \arg \min_{\Phi z = y_j} \|z\|_{l_1^d}$.

Wybór optymalnego kierunku: Odnajdź indeks j_0 kolumny, dla której odzyskany wektor ma największą normę euklidesową (co minimalizuje wpływ szumu i błędów, wskazując punkt o największym gradiencie):

$$j_0 = \arg \max_{j=1, \dots, m_\mathcal{X}} \|\hat{x}_j\|_{l_2^d}$$

Normalizacja: Ostateczną estymatę wektora parametrów liniowych oblicz jako:

$$\hat{a} = \frac{\hat{x}_{j_0}}{\|\hat{x}_{j_0}\|_{l_2^d}}$$

Konstrukcja funkcji aproksymującej: Zdefiniuj jednowymiarową funkcję $\hat{g}(y) := f(\hat{a}^T y)$, a ostateczną, wysokowymiarową aproksymację jako $\hat{f}(x) := \hat{g}(\hat{a} \cdot x)$.

2.3 Analiza matematyczna dla Algorytmu 1

W niniejszym podrozdziale przeprowadzimy rygorystyczną analizę matematyczną algorytmu zaproponowanego do odzyskiwania funkcji postaci $f(x) = g(a \cdot x)$. Celem tej analizy jest oszacowanie błędu aproksymacji $\|f - \hat{f}\|_\infty$ z odpowiednio wysokim prawdopodobieństwem. Dowód głównego twierdzenia rozbijemy na szereg lematów pomocniczych, które pozwolą nam opanować błędy wynikające z próbkowania skompresowanego, szumu oraz losowego doboru punktów.

2.3.1 Główne twierdzenie o błędzie aproksymacji

Zacznijmy od sformułowania głównego rezultatu, którego dowód będzie zwięźleniem tej części pracy.

Twierdzenie 2.1 (Zbieżność Algorytmu 1 [7]). *Niech $0 < s < 1$ oraz $\log d \leq m_\Phi \leq [\log 6]^{-2}d$. Wówczas istnieje stała c'_1 , taka że wykorzystując $m_\chi \cdot (m_\Phi + 1)$ ewaluacji funkcji f , Algorytm 1 definiuje funkcję $\hat{f} : B_{\mathbb{R}^d}(1 + \bar{\epsilon}) \rightarrow \mathbb{R}$, która z prawdopodobieństwem co najmniej*

$$1 - \left(e^{-c'_1 m_\Phi} + e^{-\sqrt{m_\Phi d}} + 2e^{-\frac{2m_\chi s^2 \alpha^2}{C_2^4}} \right)$$

spełnia nierówność

$$\|f - \hat{f}\|_\infty \leq 2C_2(1 + \bar{\epsilon}) \frac{\nu_1}{\sqrt{\alpha(1 - s) - \nu_1}},$$

gdzie

$$\nu_1 = C' \left(\left[\frac{m_\Phi}{\log(d/m_\Phi)} \right]^{1/2-1/q} + \frac{\epsilon}{\sqrt{m_\Phi}} \right)$$

oraz C' zależy tylko od stałych C_1 i C_2 definiujących model.

Aby udowodnić to twierdzenie, wprowadzimy teraz niezbędne fakty z teorii próbkowania skompresowanego oraz rachunku prawdopodobieństwa.

2.3.2 Narzędzia z teorii próbkowania skompresowanego

Fundamentem działania algorytmu jest zastosowanie macierzy pomiarowej spełniającej własność ograniczonej izometrii (RIP). Własność tę opisuje poniższe twierdzenie, stanowiące specjalizację twierdzenia 1.2 z [15], dla macierzy Bernoulliego.

Twierdzenie 2.2. *Załóżmy, że Φ jest losową macierzą wymiaru $m \times d$, w której wszystkie wpisy są niezależnymi zmiennymi o rozkładzie Bernoulliego przeskalowanymi przez $1/\sqrt{m}$.*

- *Dla $0 < \delta < 1$ istnieją stałe $c_1, c_2 > 0$ takie, że z prawdopodobieństwem co najmniej $1 - e^{-c_1 m}$, macierz Φ posiada własność RIP (Restricted Isometry Property):*

$$(1 - \delta)\|x\|_{l_2^d}^2 \leq \|\Phi x\|_{l_2^m}^2 \leq (1 + \delta)\|x\|_{l_2^d}^2,$$

dla wszystkich $x \in \mathbb{R}^d$ takich, że $\# \text{supp}(x) \leq c_2 m / \log(d/m)$.

- Jeśli $d > [\log 6]^2 m$, to istnieją stałe $C, c'_1, c'_2 > 0$ takie, że z prawdopodobieństwem co najmniej $1 - e^{-c'_1 m} - e^{-\sqrt{m}d}$ dla każdego wektora $x \in \mathbb{R}^d$, szumu $\epsilon \in \mathbb{R}^m$ i naturalnego $K \leq c'_2 m / \log(d/m)$ zachodzi ograniczenie odzyskiwania sygnału:

$$\|\Delta(\Phi x + \epsilon) - x\|_{l_2^d} \leq C(K^{-1/2} \sigma_K(x)_{l_1^d} + \max\{\|\epsilon\|_{l_2^m}, \sqrt{\log d} \|\epsilon\|_{l_\infty^m}\}),$$

gdzie $\sigma_K(x)_{l_1^d}$ jest błędem najlepszej K -członowej aproksymacji wektora x w normie l_1 .

Twierdzenie to podajemy bez dowodu. Jego pierwsza część jest powszechnie znanym wynikiem z teorii próbkowania skompresowanego [1, 6], natomiast druga część stanowi relatywnie nowy rezultat, wynikający z prac Wojtaszczyka [15] połączonych z ustaleniami DeVore'a, Petrovej i Wojtaszczyka [5].

Aplikując Twierdzenie 2.2 do układu równań z Algorytmu 1, uzyskujemy kluczowy wniosek szacujący błąd odzyskania kolumn x_j :

Wniosek 2.1. Niech $d > [\log 6]^2 m_\Phi$.

- Z prawdopodobieństwem co najmniej $1 - (e^{-c'_1 m_\Phi} + e^{-\sqrt{m_\Phi}d})$, wszystkie wektory $\hat{x}_j = \Delta(y_j)$ wyliczone w Algorytmie 1 spełniają:

$$\|x_j - \hat{x}_j\|_{l_2^d} \leq C \left(\left[\frac{m_\Phi}{\log(d/m_\Phi)} \right]^{1/2-1/q} + \max\{\|\epsilon_j\|_{l_2^{m_\Phi}}, \sqrt{\log d} \|\epsilon_j\|_{l_\infty^{m_\Phi}}\} \right).$$

- Jeśli dodatkowo $m_\Phi \geq \log d$, to z tym samym prawdopodobieństwem zachodzi:

$$\|x_j - \hat{x}_j\|_{l_2^d} \leq C' \left(\left[\frac{m_\Phi}{\log(d/m_\Phi)} \right]^{1/2-1/q} + \frac{\epsilon}{\sqrt{m_\Phi}} \right)$$

gdzie stałe zależą tylko od C_1 i C_2 .

Dowód. Twierdzenie 2.2 aplikujemy do równania $y_j = \Phi x_j + \epsilon_j$ dla $K \leq c'_2 m_\Phi / \log(d/m_\Phi)$. Ze względu na strukturę X , każda jej kolumna to przeskalowany wektor a^T , tj. $x_j = g'(a \cdot \xi_j) a^T$. Błąd najlepszej aproksymacji szacujemy więc następująco:

$$K^{-1/2} \sigma_K(x_j)_{l_1^d} \leq |g'(a \cdot \xi_j)| \cdot \|a\|_{l_q^d} \cdot K^{1/2-1/q} \leq C_1 C_2 \left[\frac{m_\Phi}{\log(d/m_\Phi)} \right]^{1/2-1/q},$$

co kończy dowód części pierwszej Wniosku 2.1. Aby udowodnić drugą część tego wniosku, szacujemy rozmiar błędów Taylora ϵ_j :

$$\|\epsilon_j\|_{l_\infty^{m_\Phi}} \leq \frac{\epsilon \|g''\|_\infty}{2m_\Phi} \left(\sum_{k=1}^d |a_k| \right)^2 \leq \frac{C_1^2 C_2}{2m_\Phi} \epsilon,$$

$$\|\epsilon_j\|_{l_2^{m_\Phi}} \leq \sqrt{m_\Phi} \|\epsilon_j\|_{l_\infty^{m_\Phi}} \leq \frac{C_1^2 C_2}{2\sqrt{m_\Phi}} \epsilon.$$

Zatem maksimum z norm wynosi:

$$\max\{\|\epsilon_j\|_{l_2^{m_\Phi}}, \sqrt{\log d} \|\epsilon_j\|_{l_\infty^{m_\Phi}}\} \leq \frac{C_1^2 C_2}{2\sqrt{m_\Phi}} \epsilon \cdot \max \left\{ 1, \sqrt{\frac{\log d}{m_\Phi}} \right\}.$$

Przy założeniu $m_\Phi \geq \log d$, czynnik z maksimum znika (ogranicza się przez 1), co daje też Wniosek 2.1. $\square$

2.3.3 Stabilność kierunkowa i koncentracja miary

Znamy już błąd bezwzględny wyznaczenia x_j . Teraz potrzebujemy pokazać, że błąd ten nie zniekształca zbyt wiele orientacji (kierunku) wyznaczonego wektora.

Lemat 2.1 (Stabilność podprzestrzeni – przypadek jednowymiarowy [7]). *Ustalmy $\hat{x} \in \mathbb{R}^d$, wektor znormalizowany $a \in \mathbb{S}^{d-1}$, skalary $\gamma \neq 0$ oraz wektor szumu $n \in \mathbb{R}^d$ o normie $\|n\|_{l_2^d} \leq \nu_1 < |\gamma|$. Jeśli przyjmujemy, że $\hat{x} = \gamma a + n$, to:*

$$\left\| \text{sign}(\gamma) \frac{\hat{x}}{\|\hat{x}\|_{l_2^d}} - a \right\|_{l_2^d} \leq \frac{2\nu_1}{\|\hat{x}\|_{l_2^d}}.$$

Dowód. Wielokrotnie wykorzystując nierówność trójkąta (oraz jej postać odwrotną) i pamiętając, że $a \in \mathbb{S}^{d-1}$, otrzymujemy:

$$\begin{aligned} \left\| \text{sign}(\gamma) \frac{\hat{x}}{\|\hat{x}\|_{l_2^d}} - a \right\|_{l_2^d} &\leq \left\| \text{sign}(\gamma) \frac{\hat{x}}{\|\hat{x}\|_{l_2^d}} - \frac{|\gamma|a}{\|\hat{x}\|_{l_2^d}} \right\|_{l_2^d} + \left\| \frac{|\gamma|a}{\|\hat{x}\|_{l_2^d}} - a \right\|_{l_2^d} \\ &\leq \frac{\|n\|_{l_2^d}}{\|\hat{x}\|_{l_2^d}} + \left| \frac{|\gamma|}{\|\hat{x}\|_{l_2^d}} - 1 \right| \leq \frac{2\nu_1}{\|\hat{x}\|_{l_2^d}}. \end{aligned}$$

co stanowi dowód lematu. $\square$

Ponieważ oszacowanie w Lemacie 2.1 jest tym lepsze, im większa jest norma $\|\hat{x}_j\|_{l_2^d}$, algorytm słusznie szuka indeksu maksymalnego j_0 . Aby zagwarantować, że to maksimum jest wystarczająco duże i nie "utonie" w szumie (tzn. $\nu_1 < |\gamma|$), potrzebujemy użyć koncentracji probabilistycznej:

Twierdzenie 2.3 (Nierówność Hoeffdinga [9]). *Niech $X_1, \dots, X_m$ będą niezależnymi zmiennymi losowymi. Załóżmy, że zmienne te są prawie na pewno ograniczone, tzn. $\mathbb{P}\{X_j - \mathbb{E}X_j \in [a_j, b_j]\} = 1$. Wówczas:*

$$\mathbb{P} \left\{ \left| \sum_{j=1}^m X_j - \mathbb{E} \left(\sum_{j=1}^m X_j \right) \right| \geq t \right\} \leq 2e^{-\frac{2t^2}{\sum_{j=1}^m (b_j - a_j)^2}}.$$

Zastosowanie tego faktu prowadzi nas do kluczowego lematu o wielkości gradientu.

Lemat 2.2 ([7]). *Ustalmy $0 < s < 1$. Wówczas z prawdopodobieństwem $1 - 2e^{-\frac{2m\chi s^2 \alpha^2}{C_2^4}}$ zachodzi nierówność:*

$$\max_{j=1, \dots, m_\chi} |g'(a \cdot \xi_j)| \geq \sqrt{\alpha(1-s)},$$

gdzie $\alpha := \mathbb{E}_\xi (|g'(a \cdot \xi)|^2)$.

Dowód. Z definicji stałych z modelu (równania (8) i (9)) mamy $\mathbb{E}X_j = \int_{\mathbb{S}^{d-1}} |g'(a \cdot \xi)|^2 d\mu_{\mathbb{S}^{d-1}}(\xi) \geq \alpha > 0$ oraz ograniczenie nośnika $X_j - \mathbb{E}X_j \in [-\alpha, C_2^2 - \alpha]$. Aplikując do tych zmiennych nierówność Hoeffdinga otrzymujemy:

$$\mathbb{P} \left\{ \left| \sum_{j=1}^{m_\chi} |g'(a \cdot \xi_j)|^2 - m_\chi \alpha \right| \geq sm_\chi \alpha \right\} \leq 2e^{-\frac{2m\chi s^2 \alpha^2}{C_2^4}}.$$

Zatem, ze wskazanym prawdopodobieństwem zachodzi:

$$\frac{1}{m_{\mathcal{X}}} \sum_{j=1}^{m_{\mathcal{X}}} |g'(a \cdot \xi_j)|^2 \geq \alpha(1-s).$$

Gdyby dla każdego indeksu j zachodziło $|g'(a \cdot \xi_j)|^2 < \alpha(1-s)$, powyższa średnia nie mogłaby być osiągnięta. Wynika stąd bezpośrednio, że relacja ta musi zachodzić dla maksimum, co kończy dowód. $\square$

2.3.4 Dowód Twierdzenia 2.1

Mając już wszystkie potrzebne do tego narzędzia, możemy przejść do dowodu Twierdzenia 2.1.

Dowód. Na mocy Lematu 2.2 wiemy, że $|g'(a \cdot \xi_{j_0})| \geq \sqrt{\alpha(1-s)}$ z prawdopodobieństwem $1 - 2e^{-\frac{2m_{\mathcal{X}}s^2\alpha^2}{C_2^4}}$. Dodatkowo, Wniosek 2.1 w połączeniu z Lematem 2.1 (podstawiając szum i błędy algorytmu) gwarantuje nam, że odzyskany kierunek $\hat{a}$ spełnia ograniczenie:

$$\|\text{sign}(g'(a \cdot \xi_{j_0}))\hat{a} - a\|_{l_2^d} \leq \frac{2\nu_1}{\sqrt{\alpha(1-s)} - \nu_1},$$

z łącznym prawdopodobieństwem $1 - \left(e^{-c_1' m_{\Phi}} + e^{-\sqrt{m_{\Phi}d}} + 2e^{-\frac{2m_{\mathcal{X}}s^2\alpha^2}{C_2^4}} \right)$.

Mając to oszacowanie podprzestrzeni, możemy wyznaczyć globalny błąd aproksymacji funkcji f . Dla dowolnego punktu $x \in B_{\mathbb{R}^d}(1 + \bar{\epsilon})$:

$$|f(x) - \hat{f}(x)| = |g(a \cdot x) - \hat{g}(\hat{a} \cdot x)| = |g(a \cdot x) - f(\hat{a}^T \hat{a} \cdot x)| = |g(a \cdot x) - g(a \cdot \hat{a}^T \hat{a} \cdot x)|.$$

Wykorzystując ograniczenie gładkościowe funkcji (C_2) oraz fakt, że $\hat{a}(I_d - \hat{a}^T \hat{a}) = 0$, kontynuujemy ciąg nierówności, wprowadzając nieznaną wartość:

$$\begin{aligned} &\leq C_2 |a \cdot x - a \cdot [\hat{a}^T \hat{a}] \cdot x| = C_2 |a \cdot (I_d - \hat{a}^T \hat{a})x| \\ &= C_2 |(a - \text{sign}(g'(a \cdot \xi_{j_0}))\hat{a}) \cdot (I_d - \hat{a}^T \hat{a})x| \end{aligned}$$

Stosując nierówność Cauchy'ego-Schwarza i zauważając, że projekcja $I_d - \hat{a}^T \hat{a}$ ma normę co najwyżej 1:

$$\leq C_2 \|a - \text{sign}(g'(a \cdot \xi_{j_0}))\hat{a}\|_{l_2^d} \cdot \|x\|_{l_2^d}.$$

Ponieważ wektor x operuje wewnątrz zdefiniowanej powłoki $1 + \bar{\epsilon}$, jego norma nie przekracza tej wartości. Ostatecznie otrzymujemy więc:

$$|f(x) - \hat{f}(x)| \leq 2C_2(1 + \bar{\epsilon}) \frac{\nu_1}{\sqrt{\alpha(1-s)} - \nu_1},$$

co w pełni udowadnia twierdzenie. $\square$

2.3.5 Uwagi o złożoności informacyjnej

Na koniec tej analizy warto udowodnić, że wyznaczona tolerancja szumu α nie zapada się wykładniczo, unikając w ten sposób kłątwy wymiarowości. Opiera się to na twierdzeniu określającym postać analityczną rzutu miary μ_k [12] oraz na rozwinięciu funkcji z uogólnionego modelu Taylora.

Twierdzenie 2.4 (Rzut miary sferycznej [12]). *Niech $1 \leq k < d$ będą liczbami naturalnymi. Wówczas miara μ_k na kuli jednostkowej $B_{\mathbb{R}^k}$, będąca rzutem (push-forward) miary $\mu_{\mathbb{S}^{d-1}}$, wyraża się wzorem:*

$$d\mu_k(y) = \frac{\Gamma(d/2)}{\pi^{k/2}\Gamma((d-k)/2)}(1 - \|y\|_{l_2^k}^2)^{\frac{d-2-k}{2}}dy.$$

Ograniczenie to pozwala nam przejść do fundamentalnego sformułowania dotyczącego redukcji błędu.

Stwierdzenie 2.1 (Spadek wielomianowy parametru α [7]). *Założmy, że $g \in C^{M+2}$ w otoczeniu zera oraz $\frac{d^l}{dx^l}g(0) = 0$ dla $l = 1, \dots, M$. Wówczas parametr koncentracji energii $\alpha(d)$ wykazuje spadek wielomianowy:*

$$\alpha(d) = \frac{\Gamma(d/2)}{\pi^{1/2}\Gamma((d-1)/2)} \int_{-1}^1 |g'(y)|^2 (1-y^2)^{\frac{d-3}{2}} dy = \mathcal{O}(d^{-M})$$

przy $d \rightarrow \infty$.

Dowód. Korzystając z rozwinięcia Taylora wokół zera dla funkcji g' , wszystkie wyrazy aż do rzędu M redukują się, co daje $|g'(y)|^2 = \left(\frac{1}{M!} \frac{d^{M+1}}{dx^{M+1}}g(0)\right)^2 y^{2M} + \mathcal{O}(y^{2M+1})$. Biorąc pod uwagę asymetryczność kuli i własności funkcji Gamma dla całek z momentami, odrzucamy nieparzyste składniki błędu. Stosując do pozostałej całki aproksymację Stirlinga ($\Gamma(z) \approx \sqrt{2\pi/z}(z/e)^z$), wyrażenie dla rzutu miary przy $d \rightarrow \infty$ transformuje się do asymptoty:

$$\alpha(d) = \mathcal{O}\left(\frac{\Gamma(d/2)\Gamma((1+2M)/2)}{\Gamma((d+2M)/2)}\right) \approx d^{-M},$$

co dowodzi potęgowej (a nie wykładniczej) degradacji użytecznego sygnału. $\square$

2.4 Rekonstrukcja w przypadku ogólnym (Algorytm 2) – Przedstawienie kroków drugiego algorytmu ($k \geq 1$), ze szczególnym uwzględnieniem roli rozkładu SVD w stabilnej ekstrakcji podprzestrzeni.

W tym podrozdziale uogólniamy nasze rozważania na przypadek, w którym wymiar ukryty $k \geq 1$. Rozważamy tu funkcje określane mianem k -grzbietowych (ang. k -ridge functions), zdefiniowane jako $f(x) = g(Ax)$. Zakładamy ponownie, że A jest macierzą wymiaru $k \times d$ o ortonormalnych wierszach ($AA^T = I_k$), a $g : B_{\mathbb{R}^k}(1 + \bar{\epsilon}) \rightarrow \mathbb{R}$ jest funkcją klasy C^2 . Podobnie jak w przypadku jednowymiarowym, punktem wyjścia jest przybliżenie pochodnej kierunkowej za pomocą twierdzenia Taylora. Dla punktu $\xi \in B_{\mathbb{R}^d}$ oraz kierunku $\varphi \in B_{\mathbb{R}^d}(r)$, otrzymujemy tożsamość:

$$[\nabla g(A\xi)^T A]\varphi = \frac{f(\xi + \epsilon\varphi) - f(\xi)}{\epsilon} - \frac{\epsilon}{2}[\varphi^T \nabla^2 f(\zeta)\varphi],$$

gdzie $\zeta(\xi, \varphi) \in B_{\mathbb{R}^d}(1 + \bar{\epsilon})$. Rozważając to równanie dla m_Φ kierunków ze zbioru Φ oraz $m_{\mathcal{X}}$ punktów próbkowania ze zbioru $\mathcal{X}$, możemy zbudować analogiczny układ macierzowy.

Zbieramy pochodne kierunkowe w macierz X wymiaru $d \times m_{\mathcal{X}}$:

$$X = (A^T \nabla g(A\xi_1), \dots, A^T \nabla g(A\xi_{m_{\mathcal{X}}})) ,$$

co pozwala nam zapisać faktoryzację:

$$\Phi X = Y - \mathcal{E},$$

gdzie Y i $\mathcal{E}$ to odpowiednio macierze różnic skończonych i błędów. Zauważmy jednak kluczową różnicę strukturalną. Macierz X możemy rozłożyć jako $X = A^T \mathcal{G}^T$, gdzie $\mathcal{G} = (\nabla g(A\xi_1)^T | \dots | \nabla g(A\xi_{m_{\mathcal{X}}})^T)^T$. Oznacza to, że kolumny macierzy X nie są już przeskalowanymi kopiami jednego wektora, lecz stanowią kombinacje liniowe k ściślejszych wektorów (wierszy macierzy A). Dzięki temu wciąż możemy stabilnie odzyskać poszczególne kolumny X z kolumn Y wykorzystując minimalizację l_1 .

2.4.1 Rola rozkładu SVD w ekstrakcji podprzestrzeni

Odzyskanie przybliżenia $\hat{X}$ to jednak nie koniec. Skoro macierz A ma rząd k , to – zakładając, że $\mathcal{G}^T$ ma pełny rząd – również macierz X będzie miała rząd k . Jeżeli wykonamy rozkład według wartości osobliwych (SVD) dla macierzy $X^T = USV^T$, przestrzeń rozpięta przez prawe wektory osobliwe będzie pokrywać się z przestrzenią rozpiętą przez wiersze macierzy A , co oznacza, że $A^T A = VV^T$. Daje to nam możliwość alternatywnej reprezentacji funkcji f :

$$f(x) = g(Ax) = g(AA^T Ax) = g(AVV^T x) =: \tilde{g}(V^T x)$$

gdzie $\tilde{g}(y) := g(AVy) = f(Vy)$. Zatem, jeśli $\hat{X}$ jest dobrym przybliżeniem X , możemy oczekiwać, że pierwsze k prawych wektorów osobliwych macierzy $\hat{X}$ wyznaczy podprzestrzeń bardzo bliską tej rozpiętej przez A . Stanowi to fundament poniższego algorytmu.

2.4.2 Algorytm 2

Algorithm 2 Algorytm aproksymacji dla $k \geq 1$

Pomiary: Dla zadanych $m_\Phi, m_\mathcal{X}$, wylosuj zbiory Φ i $\mathcal{X}$, a następnie skonstruuj macierz Y wykorzystując ilorazy różnicowe.

Minimalizacja l_1 : Wyznacz przybliżenie każdej kolumny macierzy rozwiązując:

$$\hat{x}_j = \Delta(y_j) := \arg \min_{\Phi z = y_j} \|z\|_{l_1^d}$$

dla $j = 1, \dots, m_\mathcal{X}$, tworząc w ten sposób macierz $\hat{X} = (\hat{x}_1, \dots, \hat{x}_{m_\mathcal{X}})$.

Rozkład SVD: Oblicz rozkład według wartości osobliwych dla przetransponowanej macierzy estymat:

$$\hat{X}^T = \begin{pmatrix} \hat{U}_1 & \hat{U}_2 \end{pmatrix} \begin{pmatrix} \hat{\Sigma}_1 & 0 \\ 0 & \hat{\Sigma}_2 \end{pmatrix} \begin{pmatrix} \hat{V}_1^T \\ \hat{V}_2^T \end{pmatrix},$$

gdzie diagonalna podmacierz $\hat{\Sigma}_1$ zawiera k największych wartości osobliwych.

Ekstrakcja macierzy: Zdefiniuj szukaną macierz parametrów liniowych jako $\hat{A} = \hat{V}_1^T$.

Aproksymacja ostateczna: Określ nową funkcję nieliniową $\hat{g}(y) := f(\hat{A}^T y)$, co pozwala na ostateczną aproksymację $\hat{f}(x) := \hat{g}(\hat{A}x)$.

Kluczem do sukcesu Algorytmu 2 jest stabilność rozkładu SVD. Jakość końcowej aproksymacji zależy tu podwójnie: po pierwsze, od błędu rekonstrukcji z użyciem l_1 (kontrolowanego przez liczbę pomiarów m_Φ); po drugie, od stabilności podprzestrzeni rozpiętej przez V^T , która wymaga, aby wartości osobliwe macierzy X były wyraźnie oddzielone od zera (co jest zależne od liczby próbek $m_\mathcal{X}$).

2.5 Analiza matematyczna dla Algorytmu 2 ($k \geq 1$)

W niniejszym podrozdziale przeprowadzimy analizę matematyczną uogólnionego algorytmu dla przypadku wielowymiarowego ($k \geq 1$). Głównym wyzwaniem, odróżniającym tę sytuację od wariantu jednowymiarowego, jest fakt, że poszukujemy całej podprzestrzeni rozpiętej przez macierz parametrów A , a nie tylko pojedynczego wektora. Wymaga to zastosowania rozkładu według wartości osobliwych (SVD) i zaawansowanych probabilistycznych nierówności macierzowych.

2.5.1 Główne twierdzenie o błędzie aproksymacji

Podobnie jak poprzednio, analizę rozpoczynamy od sformułowania ostatecznego ograniczenia na błąd aproksymacji.

Twierdzenie 2.5 (Zbieżność Algorytmu 2 [7]). *Niech $\log d \leq m_\Phi \leq [\log 6]^2 d$. Wówczas istnieje stała c'_1 taka, że wykorzystując $m_\mathcal{X} \cdot (m_\Phi + 1)$ ewaluacji funkcji f , Algorytm 2 definiuje funkcję $\hat{f} : B_{\mathbb{R}^d}(1 + \bar{\epsilon}) \rightarrow \mathbb{R}$, która z prawdopodobieństwem co najmniej*

$$1 - \left(e^{-c'_1 m_\Phi} + e^{-\sqrt{m_\Phi d}} + k e^{\frac{-m_\mathcal{X} \alpha s^2}{2k C_2^2}} \right)$$

spełnia nierówność

$$\|f - \hat{f}\|_\infty \leq 2C_2 \sqrt{k}(1 + \bar{\epsilon}) \frac{\nu_2}{\sqrt{\alpha(1 - s) - \nu_2}},$$

gdzie

$$\nu_2 = C \left(k^{1/q} \left[\frac{m_\Phi}{\log(d/m_\Phi)} \right]^{1/2-1/q} + \frac{\epsilon k^2}{\sqrt{m_\Phi}} \right),$$

a stała C zależy tylko od C_1 i C_2 definiujących model.

2.5.2 Rekonstrukcja macierzy pomiarowej

W pierwszym kroku musimy oszacować błąd odzyskania całej macierzy X za pomocą optymalizacji l_1 . Aplikując Twierdzenie 2.2 kolumna po kolumnie, uzyskujemy następujący wniosek:

Wniosek 2.2. *Niech $\log d \leq m_\Phi \leq [\log 6]^2 d$. Wówczas z prawdopodobieństwem co najmniej $1 - (e^{-c_1 m_\Phi} + e^{-\sqrt{m_\Phi} d})$ macierz $\hat{X}$ wyliczona w Algorytmie 2 spełnia:*

$$\|X - \hat{X}\|_F \leq C \sqrt{m_\mathcal{X}} \left(k^{1/q} \left[\frac{m_\Phi}{\log(d/m_\Phi)} \right]^{1/2-1/q} + \frac{\epsilon k^2}{\sqrt{m_\Phi}} \right) = \sqrt{m_\mathcal{X}} \nu_2,$$

gdzie C zależy wyłącznie od C_1 i C_2 .

Dowód. Dowód przebiega analogicznie do Wniosku 2.1. Rozkładamy normę Frobeniusa na sumę błędów poszczególnych kolumn: $\|X - \hat{X}\|_F^2 = \sum_{j=1}^{m_\mathcal{X}} \|x_j - \hat{x}_j\|_{l_2^d}^2$. Najlepszą K -członową aproksymację dla kolumny szacujemy używając własności normy macierzy A : $\|x_j\|_{l_2^d} \leq C_1 C_2 k^{1/q}$. Po wstawieniu tych wartości oraz oszacowaniu norm błędów Taylora $\|\epsilon_j\|_{l_2^{m_\Phi}}$ i $\|\epsilon_j\|_{l_\infty^{m_\Phi}}$ z uwzględnieniem czynnika k^2 , a następnie po zsumowaniu błędów dla $m_\mathcal{X}$ kolumn, otrzymujemy żadaną tezę. $\square$

2.5.3 Stabilność podprzestrzeni SVD i macierzowe nierówności koncentracyjne

Ponieważ ekstrakcja właściwych kierunków z macierzy $\hat{X}$ opiera się na rozkładzie SVD, musimy zagwarantować stabilność wyznaczonych podprzestrzeni. Służy do tego klasyczne twierdzenie Wedina [14].

Twierdzenie 2.6 (Twierdzenie Wedina o ograniczeniu perturbacji [14]). *Jeśli istnieje $\bar{\alpha} > 0$ takie, że dla wartości osobliwych macierzy B i $\hat{B}$ zachodzi separacja $\min_i |\sigma_i(\hat{\Sigma}_1)| \geq \bar{\alpha}$ oraz znikają odpowiednie luki między blokami, to odległość podprzestrzeni rozpiętych przez pierwsze k prawych wektorów osobliwych (V_1 i $\hat{V}_1$) można oszacować jako:*

$$\|V_1 V_1^T - \hat{V}_1 \hat{V}_1^T\|_F \leq \frac{2}{\bar{\alpha}} \|B - \hat{B}\|_F.$$

Aplikując to do naszej macierzy i wykorzystując nierówność Weyla ($\sigma_k(\hat{X}^T) \geq \sigma_k(X^T) - \|X - \hat{X}\|_F$), otrzymujemy:

$$\|V_1 V_1^T - \hat{V}_1 \hat{V}_1^T\|_F \leq \frac{2\sqrt{m_{\mathcal{X}}}\nu_2}{\sigma_k(X^T) - \sqrt{m_{\mathcal{X}}}\nu_2}.$$

Aby to oszacowanie miało sens, k -ta wartość osobliwa oryginalnej macierzy X^T musi być oddzielona od zera. Ponieważ $X^T X$ jest sumą losowych macierzy dodatnio półokreślonych, posłużymy się niezwykle silnym narzędziem, jakim jest macierzowa nierówność Chernoffa w sformułowaniu Troppa [13].

Twierdzenie 2.7 (Macierzowa nierówność Chernoffa [13]). *Rozważmy $X_1, \dots, X_m$ niezależnych, losowych macierzy dodatnio półokreślonych o wymiarze $k \times k$, spełniających prawie na pewno $\sigma_1(X_j) \leq C$. Jeśli $\mu_{\min} = \sigma_k(\sum_{j=1}^m \mathbb{E}X_j)$, to dla każdego $s \in (0, 1)$ zachodzi:*

$$\mathbb{P} \left\{ \sigma_k \left(\sum_{j=1}^m X_j \right) \leq (1-s)\mu_{\min} \right\} \leq k e^{\frac{-\mu_{\min}s^2}{2C}}.$$

Prowadzi to nas do bezpośredniego oszacowania dla najmniejszej wartości osobliwej naszej macierzy:

Lemat 2.3. *Dla dowolnego $s \in (0, 1)$ zachodzi:*

$$\sigma_k(X^T) \geq \sqrt{m_{\mathcal{X}}\alpha(1-s)}$$

z prawdopodobieństwem $1 - k e^{\frac{-m_{\mathcal{X}}\alpha s^2}{2kC_2^2}}$.

Dowód. Dowód polega na zastosowaniu Twierdzenia 2.7 do macierzy kowariancji gradientów $\mathcal{G}^T \mathcal{G} = \sum_{j=1}^{m_{\mathcal{X}}} \nabla g(A\xi_j) \nabla g(A\xi_j)^T$. Zauważamy, że $\sigma_1(\nabla g(A\xi_j) \nabla g(A\xi_j)^T) \leq kC_2^2 =: C$ prawie na pewno. Wartość oczekiwana to $\mu_{\min} = m_{\mathcal{X}}\sigma_k(H_g) \geq m_{\mathcal{X}}\alpha > 0$. Podstawiając te wartości do nierówności Chernoffa i biorąc pierwiastek kwadratowy, wprost otrzymujemy poszukiwane prawdopodobieństwo i ograniczenie. $\square$

2.5.4 Dowód Twierdzenia 2.5

Mając zabezpieczoną rekonstrukcję normy macierzy oraz stabilność jej podprzestrzeni, integrujemy te wyniki, by zakończyć dowód głównego twierdzenia dla wielowymiarowego algorytmu.

Dowód. Korzystając łącznie z Wniosku 2.2, Twierdzenia 2.6 oraz Lematu 2.3, redukujemy czynnik $\sqrt{m_{\mathcal{X}}}$ z licznika i mianownika ograniczenia Wedina. Otrzymujemy, że z prawdopodobieństwem co najmniej

$$1 - \left(e^{-c'_1 m_{\Phi}} + e^{-\sqrt{m_{\Phi}d}} + k e^{\frac{-m_{\mathcal{X}}\alpha s^2}{2kC_2^2}} \right)$$

zachodzi ograniczenie dla rzutów ortogonalnych (a z racji na konstrukcję algorytmu, również dla zrekonstruowanej macierzy $\hat{A}$) :

$$\|A^T A - \hat{A}^T \hat{A}\|_F = \|V_1 V_1^T - \hat{V}_1 \hat{V}_1^T\|_F \leq \frac{2\nu_2}{\sqrt{\alpha(1-s)} - \nu_2}.$$

Przechodzimy teraz do wyznaczenia ostatecznego błędu na funkcji f . Ponieważ macierz A posiada ortonormalne wiersze, zachodzi $A = AA^T A$. Wykorzystując to, dla dowolnego $x \in B_{\mathbb{R}^d}(1 + \bar{\epsilon})$ mamy:

$$\begin{aligned} |f(x) - \hat{f}(x)| &= |g(Ax) - g(A\hat{A}^T \hat{A}x)| \\ &\leq C_2 \sqrt{k} \|Ax - A\hat{A}^T \hat{A}x\|_{l_2^k} \\ &= C_2 \sqrt{k} \|A(A^T A - \hat{A}^T \hat{A})x\|_{l_2^k}. \end{aligned}$$

Korzystając z własności norm dla macierzy podrzędnej:

$$\leq C_2 \sqrt{k} \|(A^T A - \hat{A}^T \hat{A})\|_F \|x\|_{l_2^d}.$$

Ponieważ promień badanej kuli wynosi co najwyżej $1 + \bar{\epsilon}$, wstawiamy uzyskane ograniczenie z Twierdzenia Wedina :

$$|f(x) - \hat{f}(x)| \leq 2C_2 \sqrt{k} (1 + \bar{\epsilon}) \frac{\nu_2}{\sqrt{\alpha(1-s)} - \nu_2},$$

co ostatecznie kończy dowód i potwierdza poprawność aproksymacji algorytmu wielowymiarowego. $\square$

2.6 Rozszerzenia modelu i ograniczenia praktyczne

We wcześniejszych podrozdziałach zakładaliśmy, że funkcja f jest zdefiniowana na kuli jednostkowej $B_{\mathbb{R}^d}$ (z niewielkim marginesem $\bar{\epsilon}$) oraz że jej wartości mogą być mierzone z idealną precyzją bez żadnego błędu. W praktycznych zastosowaniach uczenia maszynowego rzadko dysponujemy tak komfortowymi warunkami. W niniejszym podrozdziale omówimy możliwości i ograniczenia naszej metody w obliczu zaszumionych pomiarów oraz dla dziedzin będących dowolnymi ciałami wypukłymi.

2.6.1 Stabilność numeryczna w obecności szumu pomiarowego

Załóżmy, że wartości funkcji podczas wyznaczania ilorazu różnicowego mogą być zmierzone jedynie z pewną skończoną precyzją. Równanie aproksymacji Taylora ulega modyfikacji i przyjmuje postać układu:

$$\Phi X = Y - \mathcal{E} + \frac{\mathcal{W}}{\epsilon},$$

gdzie w_{ij} (elementy macierzy $\mathcal{W}$) reprezentują różnicę pomiędzy dokładną wartością różnicy $f(\xi_j + \epsilon \varphi_i) - f(\xi_j)$ a jej zmierzoną, zaszumioną wersją.

Prowadzi to do zmodyfikowanego problemu próbkowania skompresowanego:

$$Y = \Phi X + \mathcal{E} - \frac{\mathcal{W}}{\epsilon}.$$

Aplikując Twierdzenie 2.2, musimy zastąpić deterministyczny błąd $\mathcal{E}$ wyrażeniem $\mathcal{E} - \mathcal{W}/\epsilon$. Jeśli założymy jedynie, że szum jest jednostajnie ograniczony (tzn. $|w_{ij}| \leq \nu$), to norma błędu rośnie wraz z liczbą próbek: $\|w_j\|_{l_2^{m_\Phi}} \leq \nu\sqrt{m_\Phi}$. Oznacza to, że im więcej punktów próbkujemy, tym bardziej wzmacniamy poziom szumu. Zjawisko to znane jest w literaturze pod nazwą zwiżania szumu (ang. *noise folding*) i stanowi istotne ograniczenie dla klasycznych estymat l_1 [7].

Aby przezwyciężyć ten problem, autorzy proponują zmianę paradygmatu i potraktowanie w_{ij} jako losowego szumu o rozkładzie normalnym $\mathcal{N}(0, \sigma^2)$. Zgodnie z wynikami Candès i Tao [2], w takich warunkach minimalizacja l_1 (z użyciem estymatora zwanego Dantzig selector) pozwala na osiągnięcie błędu:

$$\|x - \hat{x}\|_{l_2^d} \leq C \cdot \sqrt{2 \log d} \cdot \sqrt{k+1} \cdot \sigma.$$

Zauważmy, że w tym oszacowaniu błąd skaluje się niezwykle korzystnie względem wymiaru przestrzeni (jedynie jako $\sqrt{\log d}$) i jest niezależny od liczby pomiarów m_Φ , co całkowicie eliminuje problem zwiżania szumu.

Eksperymenty numeryczne przeprowadzone w pracy [7] dla wymiaru $d = 1000$ wyraźnie potwierdzają tę teoretyczną właściwość – współczynnik pomyślnej rekonstrukcji macierzy rzadkiej rośnie płynnie i stabilnie wraz ze spadkiem wariancji szumu bez drastycznych załamania przy dużej liczbie próbek.

2.6.2 Aproksymacja na dowolnych ciałach wypukłych

Uczenie funkcji wielowymiarowych często nie ogranicza się do kuli euklidesowej. Przedstawione algorytmy można uogólnić na dowolne, domknięte ciało wypukłe $\Omega \subset \mathbb{R}^d$.

Wymaga to dwóch modyfikacji modelu. Po pierwsze, macierz kowariancji gradientów wyznaczamy całkując po dziedzinie Ω względem zadanej miary probabilistycznej μ_Ω :

$$H^f := \int_{\Omega} \nabla f(x) \nabla f(x)^T d\mu_\Omega(x).$$

Po drugie, funkcja musi być zdefiniowana na ϵ -otoczeniu dziedziny, tj. $\Omega + \bar{\epsilon} := \{x \in \mathbb{R}^d : \text{dist}(\Omega, x) \leq \bar{\epsilon}\}$.

Z perspektywy dowodu błędu (dla $k = 1$), kluczowa różnica pojawia się w momencie definiowania ostatecznej aproksymacji $\hat{g}$. Dla dowolnego $y \in B_{\mathbb{R}}$ musimy algorytmicznie znaleźć punkt $x_y \in \Omega + \bar{\epsilon}$ taki, że $\hat{a} \cdot x_y = y$.

Jeżeli operacja ta jest możliwa, Twierdzenie 2.1 nadal zachodzi, jednak oszacowanie ostatecznego błędu ulega powiększeniu o średnicę dziedziny (mierzoną w normie l_2):

$$\|f - \hat{f}\|_{\infty} \leq 2C_2(\text{diam}(\Omega) + 2\bar{\epsilon}) \frac{\nu_1}{\sqrt{\alpha(1-s)} - \nu_1}.$$

Głównym mankamentem tego uogólnienia jest fakt, że średnica $\text{diam}(\Omega) = \max_{x, x' \in \Omega} \|x - x'\|_{l_2^d}$ może rosnąć wraz z wymiarem. Przykładowo, dla hiperkostki $\Omega = [-1, 1]^d$ średnica wynosi $\sqrt{2d}$, co ponownie wprowadza zależność błędu od wymiaru d [7]. Ograniczenie to stanowi otwarty problem badawczy, którego rozwiązanie może w przyszłości opierać się na funkcjonalach Minkowskiego i estymatach w dualnych normach l_1 .

3 Opis implementacji oraz doświadczenia numeryczne

Po przeprowadzeniu rygorystycznej analizy matematycznej w Rozdziale 2, w której wykazaliśmy, że z odpowiednio wysokim prawdopodobieństwem algorytmy oparte na próbkowaniu skompresowanym potrafią przełamać klątwę wymiarowości, niniejszy rozdział poświęcony jest weryfikacji tych rezultatów w praktyce. Teoretyczne gwarancje, opierające się na własności ograniczonej izometrii (RIP), macierzowych nierównościach Chernoffa oraz twierdzeniu Wedina, dostarczają solidnych fundamentów, jednak to eksperymenty numeryczne pozwalają w pełni ocenić stabilność i wydajność zaproponowanych metod w rzeczywistych warunkach obliczeniowych. Celem tego rozdziału jest szczegółowe omówienie procesu implementacji Algorytmu 1 (dla $k = 1$) oraz Algorytmu 2 (dla $k \geq 1$), a także zbadanie ich zachowania w zależności od doboru hiperparametrów modelu. W szczególności interesować nas będzie wpływ liczby kierunków pomiarowych m_Φ , liczby punktów próbkowania $m_\mathcal{X}$ oraz kroku różnicy skończonej ϵ na jakość zrekonstruowanej macierzy parametrów liniowych A . Ponadto, weryfikacji poddana zostanie stabilność algorytmów w obecności zakłóceń. Jak zasygnalizowano w analizie teoretycznej, metody oparte na minimalizacji normy l_1 wykazują określoną odporność na szum, jednak istotne jest zbadanie zjawiska tzw. zwijania szumu (ang. *noise folding*) w warunkach systematycznych błędów pomiarowych. W ramach testów odtworzymy eksperymenty numeryczne zaproponowane przez Wybórę i współautorów, w tym badanie funkcji testowej w bardzo wysokim wymiarze ($d = 1000$), której pomiary zostały celowo zaburzone szumem Gaussa o różnej wariancji. Struktura niniejszego rozdziału przedstawia się następująco:

- **Podrozdział 3.1: Środowisko obliczeniowe i narzędzia programistyczne** – Opis wykorzystanych języków programowania, bibliotek do optymalizacji wypukłej (rozwiązywania problemów minimalizacji l_1) oraz procedur algebry liniowej (m.in. dekompozycji SVD).
- **Podrozdział 3.2: Szczegóły implementacyjne algorytmów** – Omówienie translacji teoretycznych kroków algorytmów na konkretne operacje numeryczne, w tym metody generowania wektorów losowych z odpowiednich miar sferycznych oraz aproksymacji pochodnych kierunkowych.
- **Podrozdział 3.3: Weryfikacja dokładności rekonstrukcji (przypadek bezszumowy)** – Testy działania algorytmów na wysoce wielowymiarowych funkcjach testowych w wyidealizowanych warunkach dokładnych pomiarów, potwierdzające ich wysoką skuteczność.

- **Podrozdział 3.4: Doświadczenia numeryczne w obecności szumu** – Analiza odporności algorytmów na zaburzenia wartości funkcji (np. szum Gaussa $\mathcal{N}(0, 1)$ skalowany parametrem $\nu \in \{0.1, 0.01, 0.001\}$) i prezentacja map sukcesu rekonstrukcji aktywnych współrzędnych.

Przeprowadzone doświadczenia numeryczne pozwolą nie tylko potwierdzić rygorystyczne oszacowania z Rozdziału 2, ale również dostarczą praktycznych wskazówek dotyczących kalibracji algorytmów w rzeczywistych zastosowaniach analizy danych i uczenia maszynowego.

3.1 Środowisko obliczeniowe i narzędzia programistyczne

3.2 Szczegóły implementacyjne algorytmów

3.3 Weryfikacja dokładności rekonstrukcji (przypadek bezszumowy)

3.4 Doświadczenia numeryczne w obecności szumu

Bibliografia

- [1] Richard Baraniuk, Mark Davenport, Ronald DeVore, and Michael Wakin. A simple proof of the restricted isometry property for random matrices. *Constructive Approximation*, 28(3):253–263, 2008. Dowód własności RIP dla macierzy losowych (Rozdział 1).
- [2] Emmanuel Candès and Terence Tao. The dantzig selector: Statistical estimation when p is much larger than n . *The Annals of Statistics*, 35(6):2313–2351, 2007. Wykorzystane w analizie odporności na szum i zjawiska noise folding.
- [3] Emmanuel J Candès, Justin Romberg, and Terence Tao. Stable signal recovery from incomplete and inaccurate measurements. *Communications on Pure and Applied Mathematics*, 59(8):1207–1223, 2006. Podstawy teorii Compressed Sensing.
- [4] Albert Cohen, Ingrid Daubechies, Ronald DeVore, Gerard Kerkyacharian, and Dominique Picard. Capturing ridge functions in high dimensions from point queries. *Constructive Approximation*, 35(2):225–243, 2012. Alternatywne podejście dla przypadku jednego wektora stochastycznego.
- [5] Ronald A DeVore, Guergana Petrova, and Przemysław Wojtaszczyk. Instance optimality in probability with an ℓ_1 -minimization decoder. *Applied and Computational Harmonic Analysis*, 27(3):275–288, 2009. Wykorzystane do dowodu błędu odzyskiwania w Twierdzeniu 3.2.
- [6] Massimo Fornasier. *Numerical Methods for Sparse Recovery*. Radon Series on Computational and Applied Mathematics. De Gruyter, Berlin, 2010.

- [7] Massimo Fornasier, Karin Schnass, and Jan Vybiral. Learning functions of few arbitrary linear parameters in high dimensions. *Foundations of Computational Mathematics*, 12(2):229–262, 2012. Główne źródło pracy.
- [8] Gene H Golub and Charles F Van Loan. *Matrix Computations*. The Johns Hopkins University Press, 3 edition, 1996. Standardowe źródło definicji SVD i algorytmów macierzowych.
- [9] Michel Ledoux. *The Concentration of Measure Phenomenon*. American Mathematical Society, Providence, Rhode Island, 2001. Kluczowe dla wyjaśnienia koncentracji miary na sferze.
- [10] Ben F Logan and Larry A Shepp. Optimal reconstruction of a function from its projections. *Duke Mathematical Journal*, 42(4):645–659, 1975. Pierwsze wprowadzenie pojęcia ridge functions.
- [11] Erich Novak and Henryk Woźniakowski. *Tractability of Multivariate Problems: Volume I: Linear Information*, volume 6 of *EMS Tracts in Mathematics*. European Mathematical Society, Zürich, 2008. Źródło dot. złożoności informacyjnej i kłątwej wymiarowości.
- [12] Walter Rudin. *Function theory in the unit ball of $\mathbb{C}^n$* . Springer-Verlag, New York-Berlin, 1980. Wzór na miarę na kuli niskowymiarowej.
- [13] Joel A Tropp. User-friendly tail bounds for sums of random matrices. *Foundations of Computational Mathematics*, 12(4):389–434, 2012. Nierówności koncentracyjne dla macierzy (Matrix Chernoff) - potrzebne do dowodu w Rozdziale 2.
- [14] Per-Åke Wedin. Perturbation bounds in connection with singular value decomposition. *BIT Numerical Mathematics*, 12(1):99–111, 1972. Twierdzenie o stabilności podprzestrzeni SVD (użyte w Algorytmie 2).
- [15] P. Wojtaszczyk. ℓ_1 minimization with noisy data. *SIAM Journal on Numerical Analysis*, 50(2):458–467, 2012.